

# **Programação II**

**+**

# **Estruturas de Dados para**

# **Bioinformática**

Formatos de dados

Hugo Pacheco

DCC/FCUP

22/23

# Dados

- Nos ficheiros que temos visto até agora, os dados estão em texto livre
- Mas têm sempre alguma estrutura, por exemplo, hierarquia de cantos e estrofes nos lusíadas

*“Canto Primeiro*

*1*

*As armas e os barões assinalados,  
Que da ocidental praia Lusitana,  
Por mares nunca de antes navegados,  
Passaram ainda além da Taprobana,  
Em perigos e guerras esforçados,  
Mais do que prometia a força humana,  
E entre gente remota edificaram  
Novo Reino, que tanto sublimaram;  
[...]*”

# Dados

- Nos ficheiros que temos visto até agora, os dados estão em texto livre
- Mas têm sempre alguma estrutura, por exemplo, informação de enzimas por linha, separada por / e ‘

*“REBASE version 302*

*staden.302*

```
=====
REBASE, The Restriction Enzyme Database  http://rebase.neb.com
Copyright (c) Dr. Richard J. Roberts, 2023.  All rights reserved.
=====
```

*Rich Roberts*

*Jan 27 2023*

```
AanI/TTA'TAA//
AarI/CACCTGCNNNN'NNNN/'NNNNNNNNNGCAGGTG//
AasI/GACNNNN'NNGTC//
AatII/GACGT'C//
[...]"
```

# Dados

- Para ler os dados temos que explorar a sua estrutura.
- Mas se estão em texto livre...
  - pode ser difícil encontrar padrões
  - cada caso é um caso
- Idealmente, diferentes conjuntos de dados devem seguir uma estrutura comum:
  - facilitar a partilha
  - garantir preservação e suporte de longo prazo
  - melhores ferramentas



# “The Web is Agreement”



[source <https://www.thewebisagreement.com/>]

# Formatos de dados

- Alguns dos formatos de dados mais comuns:
  - **Markdown (MD)**
  - HyperText Markup Language (HTML)
  - **Comma Separated Value (CSV)**
  - Excel (XLS)
  - **JavaScript Object Notation (JSON)**
  - eXtended Markup Language (XML)
  - Structured Query Language (SQL)
  - ...
- Fáceis de ler em Python!



# Markdown

- ficheiros de texto em que se usa caracteres especiais para formatação
- formato “standard” para notas, blogs ou gerar HTML

```
# Projeto 1 - Análise de texto

Neste primeiro projeto vamos relembrar alguns conceitos base da programação em Python.

Aceda ao repositório [replit](https://replit.com/@up652136/Prog2-Proj1) do Projeto 1.

- Criando uma conta no [replit](https://replit.com/) e fazendo `Fork` do projeto.
- Pode consultar os ficheiros individuais na pasta [projeto1](../scripts/projeto1).
- Pode fazer download de todo o projeto como um arquivo zip [aqui](../scripts/projeto1.zip).

Neste projeto vamos processar o texto completo do *Sermão de Santo António aos Pastores*.

## Tarefa 1

Faça download para uma pasta local do ficheiro [sermao.txt](../scripts/projeto1/sermao.txt).

Complete a função `leTexto` que lê o conteúdo de um ficheiro de texto para uma lista de strings.

## Tarefa 2

Analise a definição da função ``organizaSermao`` que organiza uma lista de linhas de texto numa lista de dicionários.

Por exemplo, para um sermão dado como a lista de linhas:



```
python
[ 'SERMÃO DE EXEMPLO'
```


```

## Projeto 1 - Análise de texto

Neste primeiro projeto vamos relembrar alguns conceitos base da programação em Python e aplicá-los no processamento de ficheiros de texto.

Aceda ao repositório [replit](#) do Projeto 1, onde pode encontrar um ficheiro `projeto1.py` :

- Criando uma conta no [replit](#) e fazendo `Fork` do projeto, pode resolver o projeto online utilizando o IDE web.
- Pode consultar os ficheiros individuais na pasta `projeto1` e fazer download dos mesmos para desenvolver o projeto no seu computador e utilizando um IDE à sua escolha.
- Pode fazer download de todo o projeto como um arquivo zip [aqui](#).

Neste projeto vamos processar o texto completo do *Sermão de Santo António aos Peixes* do Padre António Vieira, extrair métricas simples e reformatar o texto.

## Tarefa 1

Faça download para uma pasta local do ficheiro [sermao.txt](#), que contém o texto integral do *Sermão de Santo António aos Peixes* do Padre António Vieira.

Complete a função `leTexto` que lê o conteúdo de um ficheiro de texto para uma lista de linhas de texto, em que cada linha de texto é uma string sem caracteres newline.

# HTML

- ficheiros de texto em que se usa a notação `<campo>texto<campo/>` para definir uma estrutura hierárquica
- formato “standard” para representar páginas web

```
<body>
<header id="title-block-header">
<h1 class="title">Projeto 1</h1>
</header>
<h1 id="projeto-1---análise-de-texto">Projeto 1 - Análise de
texto</h1>
<p>Neste primeiro projeto vamos relembrar alguns conceitos base da
programação em Python e aplicá-los no processamento de ficheiros de
texto.</p>
<p>Aceda ao repositório <a
href="https://replit.com/@up652136/Prog2-Proj1">replit</a> do
Projeto 1, onde pode encontrar um ficheiro
<code>projeto1.py</code>:</p>
<ul>
<li>Criando uma conta no <a href="https://replit.com/">replit</a> e
fazendo <code>Fork</code> do projeto, pode resolver o projeto online
utilizando o IDE web.</li>
<li>Pode consultar os ficheiros individuais na pasta <a
href="../scripts/projeto1">projeto1</a> e fazer download dos mesmos
para desenvolver o projeto no seu computador e utilizando um IDE à
sua escolha.</li>
<li>Pode fazer download de todo o projeto como um arquivo zip <a
href="../scripts/projeto1.zip">aqui</a>.</li>
</ul>
<p>Neste projeto vamos processar o texto completo do <em>Sermão de
Santo António aos Peixes</em> do <em>Padre António Vieira</em>,
extrair métricas simples e reformatar o texto.</p>
<h2 id="tarefa-1">Tarefa 1</h2>
<p>Faça download para uma pasta local do ficheiro <a
href="../scripts/projeto1/dados/sermao.txt">sermao.txt</a> que
```



## Projeto 1 - Análise de texto

Neste primeiro projeto vamos relembrar alguns conceitos base da programação em Python e aplicá-los no processamento de ficheiros de texto.

Aceda ao repositório replit do Projeto 1, onde pode encontrar um ficheiro `projeto1.py`:

- Criando uma conta no replit e fazendo Fork do projeto, pode resolver o projeto online utilizando o IDE web.
- Pode consultar os ficheiros individuais na pasta projeto1 e fazer download dos mesmos para desenvolver o projeto no seu computador e utilizando um IDE à sua escolha.
- Pode fazer download de todo o projeto como um arquivo zip aqui.

Neste projeto vamos processar o texto completo do *Sermão de Santo*



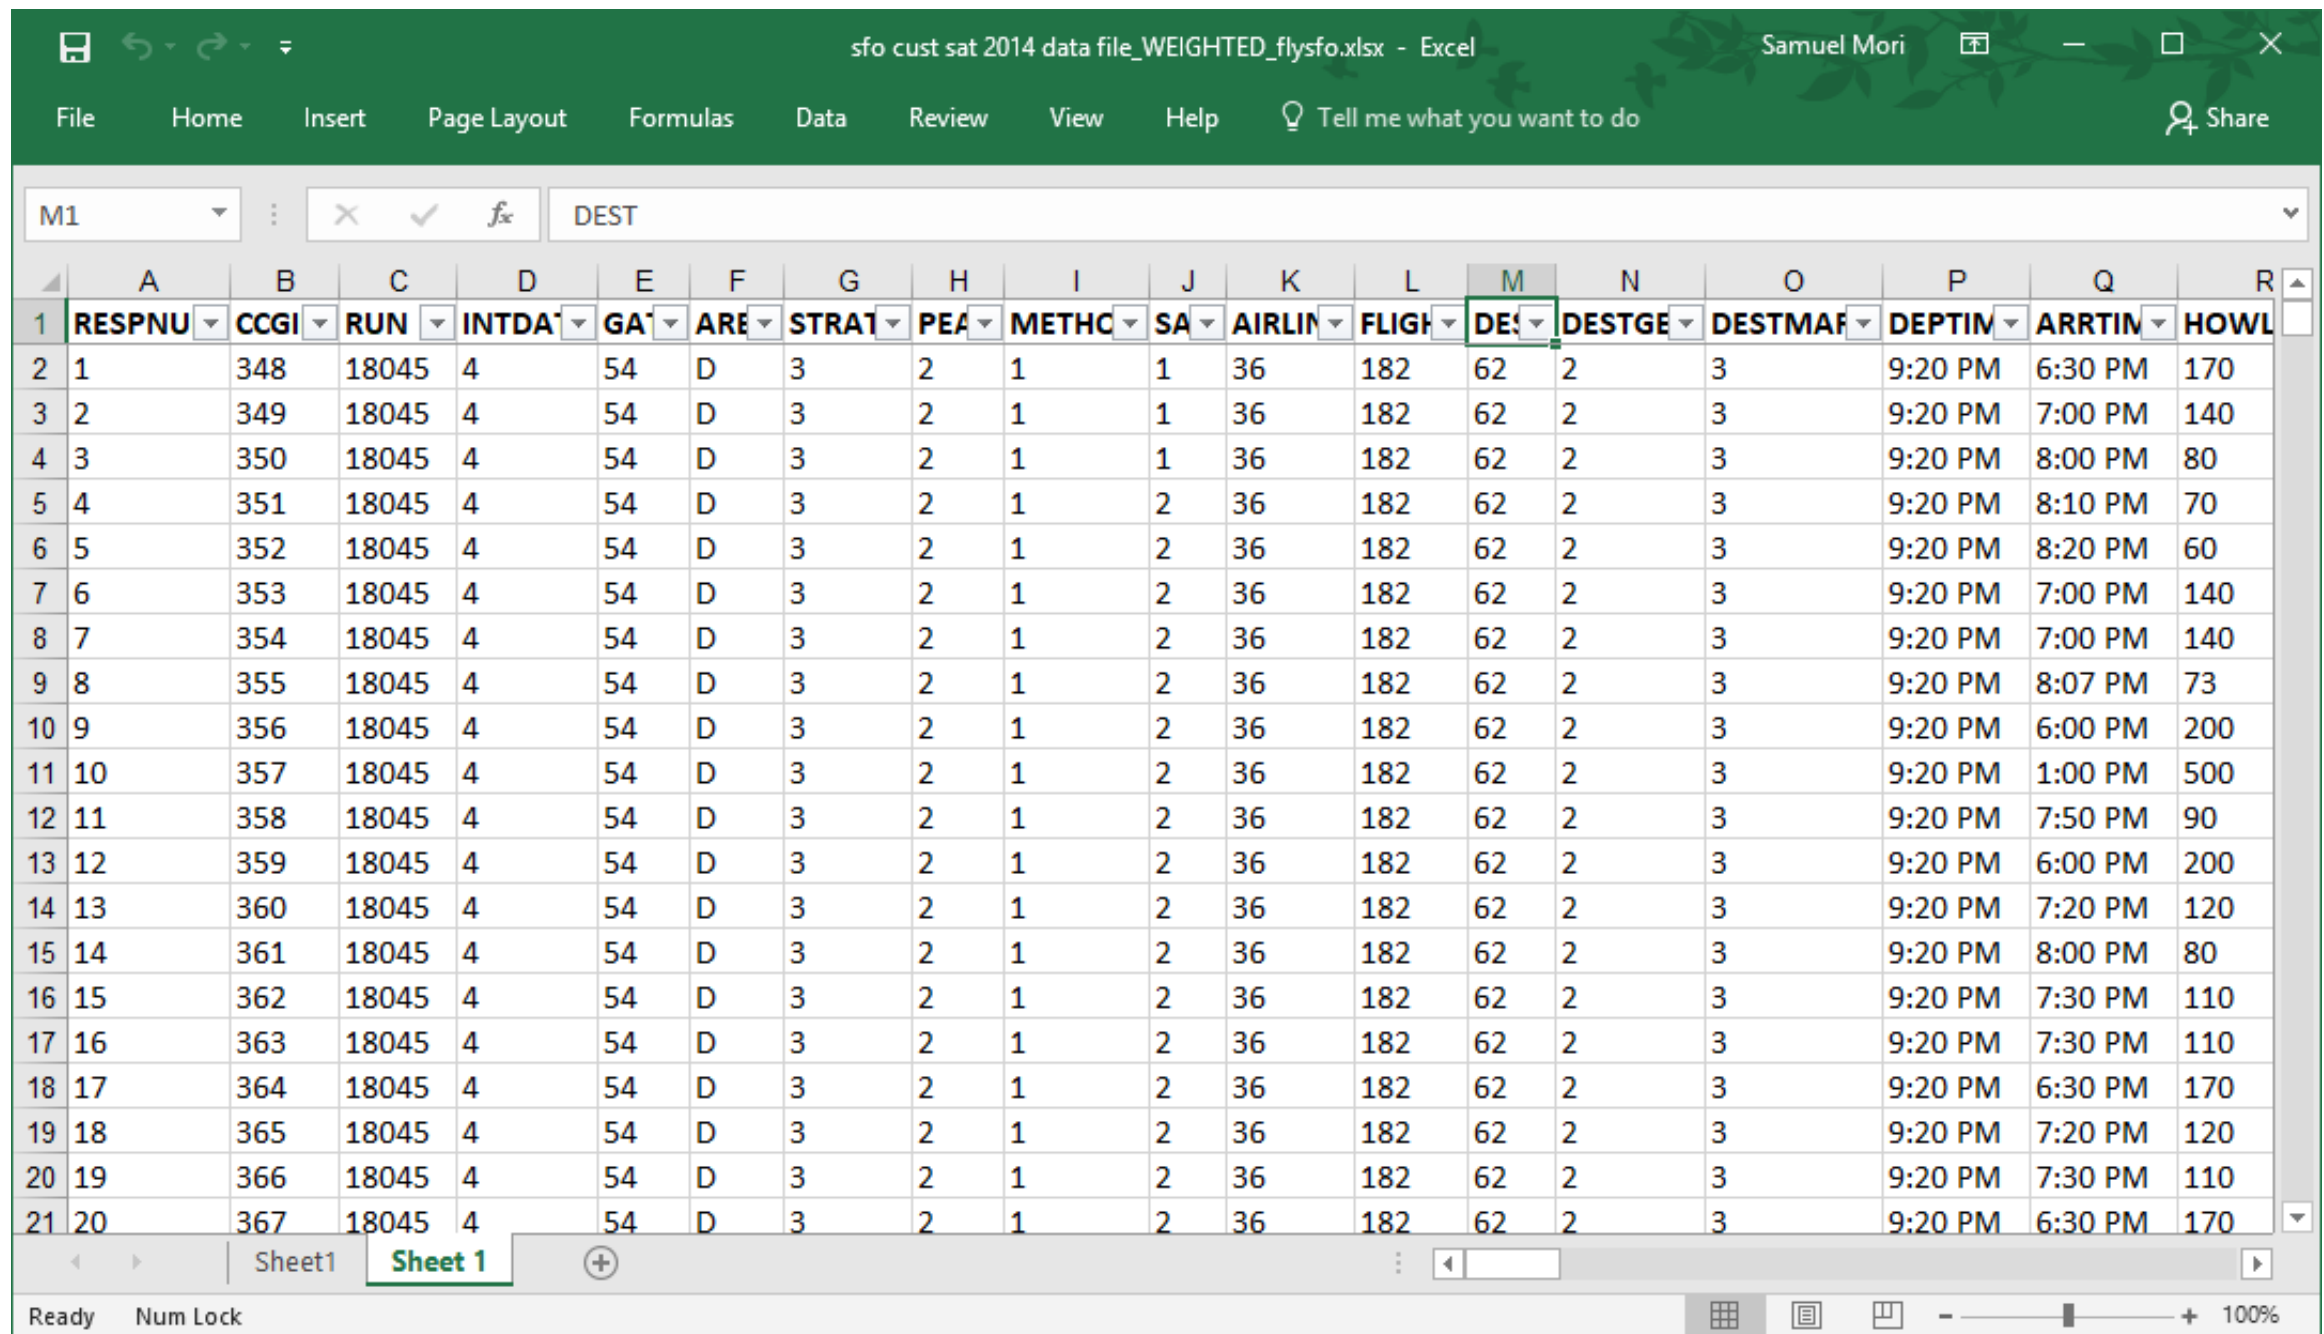
# CSV

- ficheiros de texto em que se usa vírgula para separar valores
- formato “standard” para comunicar dados tabulares

[illegible]

# Excel

- O mesmo exemplo em folhas de cálculo



sfo cust sat 2014 data file\_WEIGHTED\_flysfo.xlsx - Excel

Samuel Mori

File Home Insert Page Layout Formulas Data Review View Help Tell me what you want to do Share

M1 : X ✓ fx DEST

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R
1	RESPNU	CCGI	RUN	INTDA	GA	ARE	STRAT	PEA	METHC	SA	AIRLIN	FLIGHT	DE	DESTGE	DESTMAF	DEPTIM	ARRTIM	HOWL
2	1	348	18045	4	54	D	3	2	1	1	36	182	62	2	3	9:20 PM	6:30 PM	170
3	2	349	18045	4	54	D	3	2	1	1	36	182	62	2	3	9:20 PM	7:00 PM	140
4	3	350	18045	4	54	D	3	2	1	1	36	182	62	2	3	9:20 PM	8:00 PM	80
5	4	351	18045	4	54	D	3	2	1	2	36	182	62	2	3	9:20 PM	8:10 PM	70
6	5	352	18045	4	54	D	3	2	1	2	36	182	62	2	3	9:20 PM	8:20 PM	60
7	6	353	18045	4	54	D	3	2	1	2	36	182	62	2	3	9:20 PM	7:00 PM	140
8	7	354	18045	4	54	D	3	2	1	2	36	182	62	2	3	9:20 PM	7:00 PM	140
9	8	355	18045	4	54	D	3	2	1	2	36	182	62	2	3	9:20 PM	8:07 PM	73
10	9	356	18045	4	54	D	3	2	1	2	36	182	62	2	3	9:20 PM	6:00 PM	200
11	10	357	18045	4	54	D	3	2	1	2	36	182	62	2	3	9:20 PM	1:00 PM	500
12	11	358	18045	4	54	D	3	2	1	2	36	182	62	2	3	9:20 PM	7:50 PM	90
13	12	359	18045	4	54	D	3	2	1	2	36	182	62	2	3	9:20 PM	6:00 PM	200
14	13	360	18045	4	54	D	3	2	1	2	36	182	62	2	3	9:20 PM	7:20 PM	120
15	14	361	18045	4	54	D	3	2	1	2	36	182	62	2	3	9:20 PM	8:00 PM	80
16	15	362	18045	4	54	D	3	2	1	2	36	182	62	2	3	9:20 PM	7:30 PM	110
17	16	363	18045	4	54	D	3	2	1	2	36	182	62	2	3	9:20 PM	7:30 PM	110
18	17	364	18045	4	54	D	3	2	1	2	36	182	62	2	3	9:20 PM	6:30 PM	170
19	18	365	18045	4	54	D	3	2	1	2	36	182	62	2	3	9:20 PM	7:20 PM	120
20	19	366	18045	4	54	D	3	2	1	2	36	182	62	2	3	9:20 PM	7:30 PM	110
21	20	367	18045	4	54	D	3	2	1	2	36	182	62	2	3	9:20 PM	6:30 PM	170

Sheet1 Sheet 1

Ready Num Lock 100%

# CSV

- Ler um ficheiro CSV em Python
- E.g., índice de secura mensal para o Porto publicado pelo IPMA [aqui](#)

```
import csv
with open('../dados/mpdsi-1312-porto.csv', 'r') as f:
    table = csv.reader(f)
    data = list(table)
print(data)
```

- Primeira linha é o cabeçalho que define o tipo de cada coluna
- Cada linha é uma lista de comprimento igual, com entradas de cada mês

```
['date', 'minimum', 'maximum', 'range', 'mean', 'std']
['2022-04-01', '-2.89150762558', '-2.75911641121', '0.132391214371', '-2.83662211895', '0.0348872640209']
['2022-05-01', '-3.8392894268', '-3.70847082138', '0.130818605423', '-3.7754253887', '0.0342999110149']
```

# CSV

- Criar dicionário de classificações

```
cabecalho=data[0]
meses = data[1:]
```

```
def classifica(n):
    if n >= 4: return 'chuva extrema'
    elif n >= 3: return 'chuva severa'
    elif n >= 2: return 'chuva moderada'
    elif n >= 1: return 'chuva fraca'
    elif n > -1: return 'normal'
    elif n > -2: return 'seca fraca'
    elif n > -3: return 'seca moderada'
    elif n > -4: return 'seca severa'
    else: return 'seca extrema'
```

```
meses_cs = { mes[0] : [classifica(float(n)) for n in mes[1:]] \
               for mes in meses }
```

Índice PDSI (Palmer Drought Severity Index) mensal por concelho (formato CSV)

## Invocação:

<https://api.ipma.pt/open-data/observation/climate/mpdsi/{distrito}/mpdsi-{DICO}-{concelho}.csv>

Notas: Taxa de atualização mensal. DICO: Identificador único de concelho (de acordo com a CAOP - DGT).

- **maior ou igual a 4,0** - Chuva extrema
- **3,00 a 4,0** - Chuva severa
- **2,00 a 3,99** - Chuva moderada
- **1,00 a 1,99** - Chuva fraca
- **-0,99 a 0,99** - Normal
- **-1,99 a -1,0** - Seca fraca
- **-2,99 a -2,0** - Seca moderada
- **-3,99 a -3,0** - Seca severa
- **menor ou igual a -4,00** - Seca extrema



# CSV

- Selecionar a previsão mais recorrente por mês

```
def count(xs):  
    c = {}  
    for x in xs: c[x] = 1 + c.get(x, 0)  
    return c  
  
def max_count(xs):  
    c = count(xs)  
    return max(c, key=lambda k : c[k])  
  
meses_c = { mes : max_count(cs) \  
            for mes, cs in meses_cs.items() }
```



# CSV

- Retornar um par com o mês mais seco de 2022 e a sua previsão

```
import dateutil.parser as date
```

```
meses_date = { date.parse(mes) : c for mes,c in meses_c.items() }  
meses_2022 = { mes.month : meses_date[mes] for mes in meses_date\  
               if mes.year == 2022 }
```

```
def desclassifica(s):  
    if s=='chuva extrema' : return 4  
    elif s=='chuva severa' : return 3  
    elif s=='chuva moderada' : return 2  
    elif s=='chuva fraca' : return 1  
    elif s=='normal' : return 0  
    elif s=='seca fraca' : return -1  
    elif s=='seca moderada' : return -2  
    elif s=='seca severa' : return -3  
    elif s=='seca extrema' : return -4  
    else : return None
```

```
mais_seco_2022 = min(meses_2022.values(),key=desclassifica)  
meses_mais_secos_2022 = { k for k,v in meses_2022.items() \  
                          if v==mais_seco_2022 }
```

# CSV

- Escrever num ficheiro CSV em Python
- E.g., guardar os índices de secura para 2022

```
meses_2022_tbl = [['mes', 'secura']] \
                 + [ [m,s] for m,s in meses_2022.items() ]
```

```
with open('test.csv', 'w') as f:
    writer = csv.writer(f, delimiter=',')
    writer.writerows(meses_2022_tbl)
```

# JSON

- ficheiros de texto key-value hierárquicos
- formato “standard” para troca de dados semi-estruturados entre aplicações

## JSON

```
1 {
2   "sessionStart": "16-03-18-12-33-09",
3   "sessionEnd": "16-03-18-12-33-12",
4   "mapName": "TestMap",
5   "logSections": [{
6     "sector": {
7       "x": 2.0,
8       "y": -1.0,
9       "z": 0.0
10    },
11    "logLines": [{
12      "time": 37.84491729736328,
13      "state": 0,
14      "action": 1,
15      "playerPosition": {
16        "x": 24.560218811035158,
17        "y": -8.940696716308594e-8,
18        "z": 3.3498525619506838
19      },
20      "cameraRotation": {
21        "x": 0.24549755454063416,
22        "y": 0.017123013734817506,
23        "z": 0.031348951160907748,
24        "w": -0.9687389135360718
25      },
26    },
27    ...
```

## XML

```
1 <?xml version="1.0" encoding="UTF-8" ?>
2 <root>
3   <sessionStart>16-03-18-12-33-09</sessionStart>
4   <sessionEnd>16-03-18-12-33-12</sessionEnd>
5   <mapName>TestMap</mapName>
6   <logSections>
7     <sector>
8       <x>2</x>
9       <y>-1</y>
10      <z>0</z>
11    </sector>
12    <logLines>
13      <time>37.84491729736328</time>
14      <state>0</state>
15      <action>1</action>
16      <playerPosition>
17        <x>24.560218811035156</x>
18        <y>-8.940696716308594e-8</y>
19        <z>3.3498525619506836</z>
20      </playerPosition>
21      <cameraRotation>
22        <x>0.24549755454063416</x>
23        <y>0.017123013734817505</y>
24        <z>0.031348951160907745</z>
25        <w>-0.9687389135360718</w>
26      </cameraRotation>
27    ...
```

# JSON

- Ler um ficheiro JSON em Python
- E.g., previsão metereológica de 5 dias para o Porto publicada pelo IPMA [aqui](#)
- JSON  $\simeq$  estruturas de dados Python

```
import json
with open('1131200.json', 'r') as f:
    dict = json.load(f)
print(dict)
```

```
{
  "owner": "IPMA",
  "country": "PT",
  "data": [{
    "precipitaProb": "100.0",
    "tMin": "7.5",
    "tMax": "14.5",
    ...}]
  ...
}
```

# JSON

- JSON = dicionários e listas aninhados uns nos outros, cujas folhas são strings, números ou booleanos
- hierárquico: estrutura aninhada, em árvore
- semi-estruturado: dicionários podem ter qualquer chave/valor; strings podem representar números, datas, etc

```
json      ::= dict
dict      ::= { string : value, ... }
value     ::= dict | sequence | basic
sequence  ::= [ value, ... ]
basic     ::= string | number | true | false | null
```



# JSON

- Obter previsão para o dia mais próximo de hoje

```
import datetime
import dateutil.parser as date

data = dict['data']
weather = { date.parse(dia['forecastDate']) \
            : dia['idWeatherType'] for dia in data }

hoje = datetime.datetime.today()
dia = min(weather, key=lambda d : abs(hoje-d))
previsao = weather[dia]
```

# JSON

- Converter código de previsão numa descrição textual
- Descrições fornecidas pelo IPMA [aqui](#)

```
with open('weather-type-classe.json', 'r') as f:  
    data = json.load(f) ['data']
```

```
classe = { d['idWeatherType']\  
          : d['descWeatherTypePT']\  
          for d in data }  
tempo = classe[previsao]
```

# JSON

- Escrever num ficheiro JSON em Python
- Permite guardar grande parte dos objetos Python em ficheiro (serialização/deserialização)
- E.g., um dicionário *{ dia : previsão textual }*, com uma formatação especial do dia



```
import calendar
def day_month(d):
    return str(d.day)+' '+calendar.month_abbr[d.month]
weather_dif = { day_month(d) : classe[w] for d,w in
weather.items() }
print(weather_dif)

with open("test.json","w") as f:
    json.dump(weather_dif,f)
with open("test.json","r") as f:
    weather_dif2 = json.load(f)
print(weather_dif2 == weather_dif)
```